

SCORING

Opération et agrégats

Calcul de l'AUC

1. Choisir le seuil de réalisation de l'évènement :

Observation	Probabilité estimée	Effectivement observé
1	0.9	1
2	0.8	0
3	0.7	1
4	0.7	0
5	0.4	0
6	0.4	1
7	0.3	1
8	0.3	0
9	0.2	0.1 ?

Total TE : 4
Total FE : 5


TE
FE
TE
FE
TE
FE
FE
TE
FE

Seuil		Cumul TE	Cumul FE	
Origine		0	0	
0.9	0.9.	1	0	Au seuil de 0,9
0.8		1	1	$FER = \frac{\text{Cumul FE}}{\Sigma FE} = \frac{0}{5} = 0$
0.7		2	2	
0.4		3	3	$TER = \frac{\text{Cumul TE}}{\Sigma TE} = \frac{2}{4} = 0.5$
0.3		4	4	
0.2		4	5	Coordonnées ROC : (0.9, 0.25)

Au seuil de 0,8

$$FER = \frac{1}{4} =$$

$$TER =$$



2. Ordonner les estimations par ordre décroissant
3. Compter les True estimations et les False estimations

Observation	Probabilité estimée	Effectivement observé
1	0.9	1 TE
2	0.8	0 FE
3	0.7	1 TE
4	0.7	0 FE
5	0.4	0 TE
6	0.4	1 FE
7	0.3	1 FE
8	0.3	0 TE
9	0.2	0 FE

Total TE = 4

Total FE = 5

Recréer une table sur la base de la précédente qui prend en observation chaque valeur distincte de probabilité estimée. Elle sera également triée par ordre décroissant de palier :

Palier	Points ajoutés	Cumul TE	Cumul FE
0.9		1	0
0.8		1	1
0.7		2	2
0.4		3	3
0.3		4	4
0.2		4	5

4. Calculer les taux à chaque palier estimé

$$FER = \frac{\text{Cumul FE}}{\Sigma FE}$$

$$TER = \frac{\text{Cumul TE}}{\Sigma TE}$$

- Au seuil de 0,9

FER 0

TER 0,25

- Au seuil de 0,8

FER 0,2

TER 0,25

- Au seuil de 0,7

FER 0,4

TER 0,5

- Au seuil de 0,4

FER 0,6

TER 0,75

- Au seuil de 0,3

FER 0,8

TER 1

- Au seuil de 0,2

FER 1


TER 1

5. Lister les coordonnées et tracer la courbe ROC

Liste des coordonnées

Coordonnées ROC
$(0; 0,25)$
$(0,2; 0,25)$
$(0,4; 0,5)$
$(0,6; 0,75)$
$(0,8; 1)$
$(1; 1)$

Courbe ROC



6. Calculer l'air entre deux coordonnées

$$Aire_i = \frac{(FER_{i+1} - FER_i) \cdot (TER_i + TER_{i+1})}{2}$$

$$Aire_1 = \frac{(FER_{1+1} - FER_1) \cdot (TER_1 + TER_{1+1})}{2} = \frac{(FER_2 - FER_1) \cdot (TER_1 + TER_2)}{2}$$

$$= \frac{(FER_2 - FER_1) \cdot (TER_1 + TER_2)}{2}$$

$$= \frac{(0 - 0) \cdot (0 + 0,25)}{2} = 0 \quad Aire_1 = 0$$

$$Aire_2 = 0,05$$

$$Aire_3 = 0,075$$

$$Aire_4 = 0,125$$

$$Aire_5 = 0,175$$

$$Aire_6 = 0,2$$

7. Calculer l'aire totale

$$AUC = \sum_{i=1}^n Aire_i$$

$$AUC = 0 + 0,05 + 0,075 + 0,125 + 0,175 + 0,2$$

$$AUC = 0,625$$

objectif 0,9 d'AUC
à minima 0,8 -

F₁-score

mesure d'équilibre du modèle

→ Compromis entre la précision et le rappel.

$$\text{Précision} = \frac{\text{Vrais positifs}}{\text{Vrais positifs} + \text{Faux Positifs}}$$

$$\text{Rappel} = \frac{\text{Vrais positifs}}{\text{Vrais}}$$

$$\text{F}_1\text{ score} = 2 \cdot \frac{\text{Précision} \cdot \text{Rappel}}{\text{Précision} + \text{Rappel}} = 2 \cdot \frac{0,5 \times 0,5}{0,5 + 0,5}$$

$$\boxed{\text{F}_1\text{ score} = 0,5} \quad = 2 \cdot \frac{0,25}{1} = 0,5$$

Précision = 0,5
Rappel = 0,5
L'équilibre est à 1.

gAUC

Différenciation par classe

Calcul du poids des groupes : $w_i = \frac{\text{Nb classe } i}{\text{Nb Total}}$ $w_1 = \frac{4}{9}$

Classe 1 :

Classe 2 : $w_2 = \frac{\text{Nb classe 2}}{\text{Nb Total}}$ $w_2 = \frac{5}{9}$

T_E et F_E par classe

Pour la classe 1 → T_E = 2 ; F_E = 2

À chaque seuil : F_{ER} et T_{ER} → Coordonnées ROC

Pour la classe 2 → T_E = 2 ; F_E = 3

À chaque seuil : F_{ER} et T_{ER} → Coordonnées ROC

Classe 1

$(0, 0)$
 $(0, 0,5)$
 $(0,5, 0,5)$
 $(1, 1)$

$(0, 0)$

Classe 2

$(0,33, 0,5)$
 $(0,66, 1)$
 $(1, 1)$

$$AUC_1 = 0, + 0,25 + 0,375 = 0,625$$

$$AUC_2 = 0,66$$

$$gAUC = \sum_{i=1}^n w_i \times AUC_i$$

$$gAUC = (w_1 \times AUC_1) + (w_2 \times AUC_2)$$

$$gAUC = \left(\frac{4}{9} \times 0,625\right) + \left(\frac{5}{9} \times 0,66\right)$$

$$gAUC \approx 0,64$$

Si le gAUC est sup à l'AUC d'une des classes de l'échantillon cela veut dire que cette classe a tendance à être sous représentée dans l'échantillon.

Accuracy

mesure la précision / exactitude globale d'un modèle

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Accuracy = \frac{2+3}{2+3+2+2} = \frac{5}{9} = 0,55$$

le modèle fait 55% de bonne prédiction -

AUC $\rightarrow$ On vise 0,9
F₁-Score $\rightarrow$ on vise 0,8
gAUC $\rightarrow$ on vise 0,85
Accuracy $\rightarrow$ On vise 0,9.

Coefficient de Gini $\rightarrow$ différenciation des observations.

$$CGini = 2 \times AUC - 1$$

1 $\rightarrow$ Différenciation parfaite
0 $\rightarrow$ " aléatoire
-1 $\rightarrow$ " imparfaite

N'apporte pas une mesure supplémentaire.
Moins intuitive.

MCC $\rightarrow$ Précision affinée

Matthews Correlation Coefficient

$$MCC = \frac{TP \times TN}{\sqrt{(TP + FP)(TN + FN)}}$$

1 $\rightarrow$ Attribution parfaite
0 $\rightarrow$ " aléatoire
-1 $\rightarrow$ " imparfaite

Test de Wald pour la significativité.